

✂ Las herramientas de análisis de datos son softwares que ayudan a procesar, visualizar e interpretar datos para obtener información valiosa y tomar decisiones.

Al usar datos, la mayoría coincide en que la calidad de la información y el análisis depende de los datos utilizados. En esencia, la entrada de datos basura implica la salida de análisis basura. La limpieza de datos, también conocida como depuración y depuración de datos, es uno de los pasos más importantes para su organización si desea crear una cultura en torno a la toma de decisiones basadas en datos de calidad.

¿Qué es la limpieza de datos?

La limpieza de datos es el proceso de corregir o eliminar datos incorrectos, corruptos, con formato incorrecto, duplicados o incompletos dentro de un conjunto de datos. Al combinar múltiples fuentes de datos, existen muchas posibilidades de que los datos se dupliquen o se etiqueten incorrectamente. Si los datos son incorrectos, los resultados y los algoritmos no son fiables, aunque parezcan correctos. No existe una única forma para la limpieza de datos, sin embargo, es fundamental establecer una plantilla para el proceso para asegurarse de que se realiza correctamente en todo momento.

¿Cuál es la diferencia entre limpieza de datos y transformación de datos?

La limpieza de datos es el proceso que elimina los datos que no pertenecen a su conjunto de datos.

La transformación de datos es el proceso de convertir datos de un formato o estructura a otro. Los procesos de transformación también se conocen como manipulación de datos, que consiste en transformar y mapear datos de un formato "sin procesar" a otro para su almacenamiento y análisis.

✂ Cómo limpiar datos

Paso 1: Eliminar observaciones duplicadas o irrelevantes

Elimine las observaciones no deseadas de su conjunto de datos, incluyendo las duplicadas o irrelevantes. Las observaciones duplicadas se producen con mayor frecuencia durante la recopilación de datos. Al combinar conjuntos de datos de diferentes fuentes, extraer datos o recibir datos de clientes o de varios departamentos, existe la posibilidad de crear datos duplicados.

Las observaciones irrelevantes se producen cuando detecta observaciones que no se ajustan al problema específico que intenta analizar. Por ejemplo, si desea analizar datos sobre clientes millennials, pero su conjunto de datos incluye generaciones anteriores, podría eliminar esas observaciones irrelevantes. Esto puede aumentar la eficiencia del análisis y minimizar las distracciones de su objetivo principal, además de crear un conjunto de datos más manejable y de mayor rendimiento.

Paso 2: Corrija los errores estructurales

Los errores estructurales se producen cuando, al medir o transferir datos, se observan convenciones de nomenclatura extrañas, errores tipográficos o uso incorrecto de mayúsculas y minúsculas. Estas inconsistencias pueden provocar categorías o clases mal etiquetadas. Por ejemplo, puede que aparezcan "N/A" y "No aplicable", pero deben analizarse como la misma categoría.

Paso 3: Filtrar valores atípicos no deseados

A menudo, habrá observaciones puntuales que, a simple vista, no parecen encajar con los datos que se están analizando. Si hay una razón legítima para eliminar un valor atípico, como una entrada incorrecta de datos, hacerlo mejorará el rendimiento de los datos con los que se trabaja. Sin embargo, a veces es la aparición de un

valor atípico lo que confirma la teoría en la que se está trabajando. Recuerde: el hecho de que exista un valor atípico no significa que sea incorrecto. Este paso es necesario para determinar la validez de esa cifra. Si un valor atípico resulta irrelevante para el análisis o es un error, considere eliminarlo.

Paso 4: Gestionar los datos faltantes

No se pueden ignorar los datos faltantes, ya que muchos algoritmos no los aceptan. Hay un par de maneras de gestionar los datos faltantes. Ninguna es óptima, pero ambas pueden considerarse.

Como primera opción, puedes descartar observaciones que tengan valores faltantes, pero al hacerlo se descartará o perderá información, así que ten esto en cuenta antes de eliminarla.

Como segunda opción, puede ingresar valores faltantes basándose en otras observaciones; nuevamente, existe la posibilidad de perder la integridad de los datos porque puede estar operando a partir de suposiciones y no de observaciones reales.

Como tercera opción, puede alterar la forma en que se utilizan los datos para navegar de manera efectiva por los valores nulos.

Paso 5: Validar y controlar la calidad

Al final del proceso de limpieza de datos, debería poder responder estas preguntas como parte de la validación básica:

¿Tienen sentido los datos?

¿Los datos siguen las reglas apropiadas para su campo?

¿Prueba o refuta su teoría de trabajo, o aporta alguna luz?

¿Puedes encontrar tendencias en los datos que te ayuden a formular tu próxima teoría?

Si no es así, ¿se debe a un problema de calidad de los datos?

Las conclusiones erróneas derivadas de datos incorrectos o "sucios" pueden influir en una estrategia empresarial y una toma de decisiones deficientes. Estas conclusiones pueden dar lugar a un momento embarazoso en una reunión de informes al darse cuenta de que sus datos no resisten el escrutinio. Antes de lograrlo, es importante crear una cultura de datos de calidad en su organización. Para ello, debe documentar las herramientas que podría utilizar para crear esta cultura y el significado que la calidad de los datos tiene para usted.